Persistência de Arquivos: Propriedades e zip

QXD0099 - Desenvolvimento de Software para Persistência

Universidade Federal do Ceará - *Campus* Quixadá

Prof. Francisco Victor da Silva Pinheiro
victorpinheiro@ufc.br

Slides baseados no material do Professor Régis Magalhães

Agenda

- Arquivos de propriedades
- Manipulação de grandes arquivos
- Checksum / Hash de grandes arquivos
- Armazenando vários arquivos em um só arquivo (arquivamento)
- Compressão de arquivos
- Encriptação de arquivos
- Leitura de arquivo ZIP

Arquivos de propriedades

- Um mapa importante é a tradicional classe Properties, que mapeia strings e é muito utilizada para a configuração de aplicações.

- A Properties possui, também, métodos para ler e gravar o mapeamento com base em um arquivo texto, facilitando muito a sua persistência.

```
user.name = angelica
user.mail = angelica@email.com
user.url = http://angelica.com.br
user.pass = 1##5932cd

book.title = Title
book.author = Author
book.edition = Edition
book.published = Published By
book.date = Published on
book.code = ISBN/ISNN
book.read = Read More about
```

Arquivos de propriedades

```
# Usando um dicionário para armazenar as propriedades
config = {
    "database.login": "scott",
    "database.password": "tiger",
    "database.url": "jdbc:mysql:/localhost/teste"
}

login = config.get("database.login")
password = config.get("database.password")
url = config.get("database.url")

# Exemplo de como poderia ser a conexão com um banco de dados em Python usando pymysql ou mysql.connector
import mysql.connector

# Estabelece a conexão usando os valores de login, password e url
connection = mysql.connector.connect(
    host="localhost",  # Retirando a parte do 'jdbc:mysql:/localhost/teste'
    database="teste",
    user=login,
    password=password
)
```

Arquivos de propriedades - gravação

```python
import configparser

# Cria um objeto ConfigParser, equivalente ao Properties em Java
config = configparser.ConfigParser()

# Adiciona as propriedades (chave-valor)
config['DEFAULT'] = {
    'database': 'localhost',
    'dbuser': 'mkyong',
    'dbpassword': 'password'
}

# Tenta gravar as propriedades no arquivo "config.ini"
with open('config.ini', 'w') as configfile:
    config.write(configfile)
```

- **configparser.ConfigParser()**: ConfigParser é uma biblioteca nativa do Python que lida com arquivos de configuração no formato .ini, semelhante ao arquivo Properties em Java.
- **config['DEFAULT']**: Define as propriedades no dicionário de configuração. No exemplo, as propriedades estão na seção DEFAULT, o que permite que sejam acessadas em qualquer parte do arquivo.
- **config.write(configfile)**: Grava o conteúdo do dicionário de configurações no arquivo config.ini.

Arquivos de propriedades - leitura

```python
import configparser

# Cria o objeto ConfigParser
config = configparser.ConfigParser()

# Lê o arquivo de propriedades (config.ini)
config.read('config.ini')

# Obtém os valores das propriedades
database = config['DEFAULT'].get('database')
dbuser = config['DEFAULT'].get('dbuser')
dbpassword = config['DEFAULT'].get('dbpassword')

# Imprime os valores
print(f"Database: {database}")
print(f"DB User: {dbuser}")
print(f"DB Password: {dbpassword}")
```

- **config.read('config.ini')**: Lê o arquivo de configuração config.ini (equivalente ao config.properties em Java).
- **config['DEFAULT'].get('database')**: Obtém o valor da chave database na seção DEFAULT. Em Python, usamos o método get() para buscar o valor associado a uma chave.
- **print()**: Imprime os valores das propriedades.

Manipulação de grandes arquivos

- **wc -l big_file.csv**: Conta o número de linhas no arquivo big_file.csv.
- **head –n 3 big_file.csv**: Exibe as primeiras 3 linhas do arquivo big_file.csv.
- **tail -n 3 big_file.csv**: Exibe as últimas 3 linhas do arquivo big_file.csv.
- **cat big_file.csv | less**: Exibe o conteúdo do arquivo big_file.csv paginado com o comando less, útil para navegar em arquivos muito grandes.
- **cat big_file.csv | grep "52.2479 21.0191"**: Procura e exibe as linhas no arquivo big_file.csv que contêm o texto "52.2479 21.0191".
- **sed "s/ /;/g" teste.txt**: Substitui todos os espaços ( ) por ponto e vírgula (;) no arquivo teste.txt. O comando sed é usado para substituições de texto.
- **ls -l | tr -s ' ' | cut -d " " -f9**: Lista os arquivos no diretório, compacta os espaços (tr -s ' ' remove espaços extras) e depois usa cut para exibir apenas o nome dos arquivos (campo 9).

Manipulação de grandes arquivos

- **ls -1**: Lista os arquivos e diretórios, um por linha.
- **awk '{ print $4 "," $5 }' teste.txt**: Exibe o 4º e o 5º campo de cada linha do arquivo teste.txt, separando-os por vírgula. O awk é usado para manipulação de texto baseado em colunas.
- **awk -F "," '{ print $4 "," $5 }' teste.csv**: Igual ao comando anterior, mas define o delimitador como vírgula (-F ",") e aplica a um arquivo CSV.
- **du -d1 | sort -n | cut -f2 | xargs du -hs**: Calcula o uso de disco para subdiretórios no diretório atual, ordena pelo tamanho, e depois exibe de forma legível (-h para "human-readable").
- **hexdump arquivo.txt**: Exibe o conteúdo do arquivo arquivo.txt no formato hexadecimal.
- **hexdump -C arquivo.txt**: Exibe o conteúdo do arquivo arquivo.txt no formato hexadecimal e caracteres ASCII, com a saída formatada.
- **hd arquivo.txt**: Uma alternativa mais curta para o comando hexdump, que também exibe o arquivo em formato hexadecimal.

Checksum / Hash de grandes arquivos

- Checksum
  - cksum teste*.*
- MD5
  - md5sum teste*.* > md5.txt
  - md5sum -c md5.txt
- SHA1
  - sha1sum teste*.* > sha1.txt
  - sha1sum -c sha1.txt

Armazenando vários arquivos em um só arquivo (arquivamento)

- tar
  - tar cfv teste.tar teste*.*
    - c – create
    - f – file
    - v - verbose

Compressão de arquivos

- **Sem perda**
  - zip, rar, 7z, gzip (um só arquivo), bzip2 (um só arquivo),...
  - zip teste.zip teste*.*
  - gzip teste.txt
  - bzip2 teste.txt
  - tar c teste*.* | gzip > teste.tar.gz
  - tar cfvz teste.tar.gz teste*.*
  - z - gzip
  - tar cfvj teste.tar.bz teste*.*
  - j – bzip2
- **Com perda**
  - jpg,mp3, mp4, ...

Encriptação de arquivos

- Encriptar:
  - gpg -c teste.txt
- Decriptar:
  - gpg teste.txt.gpg
- http://www.techrepublic.com/article/how-to-easily-encryptdecrypt-a-file-in-linux-with-gpg/
- http://irtfweb.ifa.hawaii.edu/~lockhart/gpg/
- https://help.ubuntu.com/community/GnuPrivacyGuardHowto

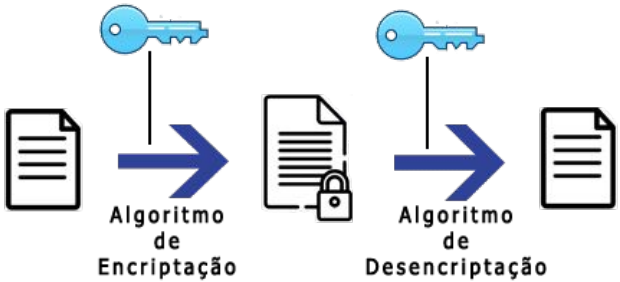

Leitura de arquivo ZIP

```python
import zipfile

# Caminho do arquivo ZIP
zip_file_path = "./teste.zip"

# Abre o arquivo ZIP para leitura
with zipfile.ZipFile(zip_file_path, 'r') as zip_ref:
    # Lista os arquivos dentro do ZIP
    for file_name in zip_ref.namelist():
        # Abre o arquivo dentro do ZIP
        with zip_ref.open(file_name) as file:
            # Lê o conteúdo do arquivo
            for line in file:
                # Converte de bytes para string e remove quebras de
linha
                print(line.decode('utf-8').strip())
```

- **zipfile.ZipFile()**: Abre o arquivo ZIP para leitura.
- **zip_ref.namelist()**: Lista os nomes dos arquivos dentro do arquivo ZIP.
- **zip_ref.open(file_name)**: Abre um arquivo específico dentro do ZIP para leitura.
- **file.read() ou iteração linha por linha**: Lê o conteúdo do arquivo compactado. Em Python, as linhas são lidas como bytes, então usamos .decode('utf-8') para convertê-las em strings.
- **.strip()**: Remove qualquer quebra de linha ou espaços adicionais.

Leitura de arquivo ZIP

```
import zipfile

# Caminho do arquivo ZIP
zip_file_path = "./tb1.zip"

# Abre o arquivo ZIP
with zipfile.ZipFile(zip_file_path, 'r') as zip_ref:
    # Pega o nome do primeiro arquivo dentro do ZIP
    file_name = zip_ref.namelist()[0]

    # Abre o arquivo dentro do ZIP
    with zip_ref.open(file_name) as file:
        # Usa o scanner (como o Scanner no Java, lendo linha por linha)
        for line in file:
            print(line.decode('utf-8').strip())  # Converte bytes para
string e remove quebras de linha
```

- **zipfile.ZipFile(zip_file_path, 'r')**: Abre o arquivo ZIP para leitura.
- **zip_ref.namelist()[0]**: Obtém o nome do primeiro arquivo dentro do ZIP.
- **zip_ref.open(file_name)**: Abre o arquivo dentro do ZIP para leitura.
- **for line in file:**: Lê o conteúdo do arquivo dentro do ZIP linha por linha.
- **.decode('utf-8').strip()**: Converte cada linha (que é lida como bytes) para uma string e remove quebras de linha ou espaços em branco adicionais.

Bibliografia Básica

- SADALAGE, P. J. E FOWLER, M. NoSQL Essencial. Editora Novatec, São Paulo, 2013.
- REDMOND, E.; WILSON, J. R. Seven Databases in Seven Weeks: A Guide to Modern Databases and the NoSQL Movement. 1ª edição, 2012. The Pragmatic Programmers.
- ULLMAN, J.D.; WIDOW, J. First Course in Database Systems. 3a edição, 2007. Prentice Hall.
- HAMBRICK, G. et al. Persistence in the Enterprise: A Guide to Persistence Technologies; 1ª edição, 2008. IBM Press.
- ELMASRI, R.; NAVATHE, S. B. Sistemas de banco de dados. 4ª edicao, 2009. Pearson/Addison-Wesley.

Bibliografia Complementar

- WHITE, Tom. Hadoop: the definitive guide. California: O´Reilly, 2009. xix, 501 p. ISBN 9780596521974 (broch.).
- AMBLER, S.W., SADALAGE, P.J. Refactoring Databases: Evolutionary Database Design. 1a edição, 2011. Addison Wesley.
- SILBERSCHATZ, A.; SUDARSHAN, S. Sistema de banco de dados. 2006. Campus.
- LYNN, B. Use a cabeça! SQL. 1ª edição, 2008. ALTA BOOKS.
- SMITH, Ben. JSON básico: conheça o formato de dados preferido da web. São Paulo: Novatec, 2015. 400 p. ISBN 9788575224366 (broch.).
- HITZLER, P., KRÖTZSCH, M., and RUDOLPH, S. (2009). Foundations of Semantic Web Technologies. Chapman & Hall/CRC.
- ANTONIOU, G. and HARMELEN, F. (2008). A Semantic Web Primer. Second Edition,Cambridge, MIT Press, Massachusetts.
- HEATH, T. and BIZER, C. (2011). Linked Data: Evolving the Web into a Global Data Space. Morgan & Claypool, 1st edition.

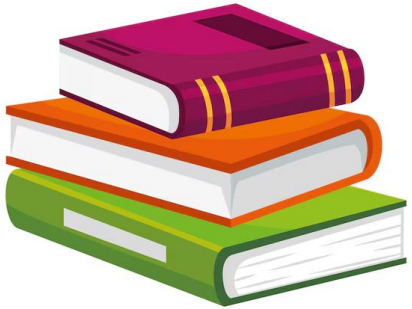

Obrigado!

Dúvidas?

Universidade Federal do Ceará - *Campus* Quixadá

Prof. Francisco Victor da Silva Pinheiro
victorpinheiro@ufc.br